Lab-Log: Vergabe-Radar

Big Data Analytics, Leistungsnachweis B (Zweierteam). Chronologisch nach CRISP-DM-Zyklen. Zahlen und Quellen stehen in `docs/iterationen.md`, `docs/business.md`, `docs/phasen/` *und* `reports/`; *hier steht die Erzählung mit den Entscheidungen. Fakten und Deutung sind getrennt gekennzeichnet. Hauptteil: Abschnitte 0 bis 11 (bis vor Anhang A); Details im Anhang A (Hashes und Commits) und B (alle KI-Irrwege). Stand: 2026-11-09.*

Erzeugt mit `src/report/lab_log.py` *aus* `docs/lab_log_vorlage.md`, `docs/zeitprotokoll.md` *und* `docs/ki_irrwege.md`; *Bilder mit* `src/report/lab_log_bilder.py`.

> **In einfachen Worten.** Wir wollten wissen, ob sich aus den Bekanntmachungen vergebener öffentlicher Aufträge (Datenbank TED, das EU-Amtsblatt für Ausschreibungen) vorhersagen lässt, wann ein Reinigungsvertrag in Deutschland neu ausgeschrieben wird, damit sich ein Betrieb früh vorbereiten kann. Wir haben dafür drei Ansätze gegen vorab festgelegte Schwellen geprüft: neue Aufträge ihren Vorgängern zuordnen, den Termin der Neuausschreibung berechnen und eine Liste der Vertragsenden bauen. Der Termin lässt sich nicht vorhersagen (Trefferquote 28,8 % statt der geforderten 60 %). Das Ende eines Vertrags lässt sich meist aus der Bekanntmachung lesen (66 von 70 Stichprobenverträgen stimmen mit zwei KI-Lesern überein), doch diese Liste gibt es schon kostenlos, und unsere Prüfung ergab keinen tragfähigen Business Case. Wir empfehlen deshalb, die Liste als Hilfsmittel zu nutzen und kein eigenes Produkt zu bauen; für einen Reinigungsbetrieb ist „kostenlos nutzen" im Modell mit Annahmen besser als „selbst bauen". Grenzen: nur drei Gespräche, die KI-Leser sind nicht unabhängig, ob jemand für die Liste zahlt, ist ungeprüft.

0. Überblick

Frage. Mittelständler (Beispiel Gebäudereinigung) wollen sich früh auf Neuausschreibungen öffentlicher Aufträge vorbereiten. Lässt sich aus den Zuschlagsbekanntmachungen auf TED (Tenders Electronic Daily) vorhersagen, wann ein Vertrag neu ausgeschrieben wird, und wäre eine Liste auslaufender Verträge ein Produkt, das sich vom Markt abhebt?

Antwort in drei Sätzen.

1. Der Termin der Neuausschreibung lässt sich mit den TED-Daten nicht brauchbar vorhersagen: Die beste einfache Regel trifft das Fenster ±3 Monate in 28,8 % der 52 geprüften Fälle (Schwelle 60 %, naive Referenz 17,3 %).
2. Brauchbar ist eine Liste der Verträge mit dem Ende ihrer Laufzeit („laut Bekanntmachung"): 6.803 von 9.325 Losen (rund 73 %) haben ein Ende der Grundlaufzeit (Abschnitt 4); 66 von 70 Stichprobenlosen (94,3 %) stimmen mit dem Vergleichswert zweier KI-Leser überein (Mensch 14/15; „die Liste ist korrekt" ist nicht belegt). Diese Art Liste gibt es aber schon kostenlos (Vergabeweiser) und günstig (AusschreibungsRadar).
3. Belegt ist nur ein Merkmalsunterschied (Ende je Los, Grundlaufzeit statt Höchstende; rund 10 % der Lose auf zwei Stichproben), kein Qualitätsvorteil beim Lesen. Zahlungsbereitschaft zeigte sich in einem von drei Gesprächen und nur für Wettbewerbsdaten; Nachfrage bleibt ungeprüft.

Verlauf. Zehn Iterationen in vier Zyklen; danach (2026-11-06 bis 11-09) Business-Case-Auswahl, Demo, Live-Demo, Video und Folienumbau (Abschnitt 5 und 6). Die Entscheidung am Ende jeder Iteration (weiter, zurück zu Phase X, Idee anpassen) war vorab an Schwellen gebunden, die vor dem Ergebnis committet wurden. Zyklus 4 entstand, weil der Dozent mehr Gewicht auf Business Understanding verlangte.

Zyklus	Iterationen	Leitfrage	Ergebnis
1	1 bis 4	Lässt sich ein neuer Auftrag seinem Vorgänger zuordnen?	Nein, jede Variante verfehlte die Schwelle; Idee angepasst
2	5	Trägt eine einfache Terminprognose?	Nein (28,8 % statt 60 %); Idee angepasst auf eine Vertragsliste
3	6 bis 9	Wie genau ist die Vertragsliste?	Brauchbar, zuletzt 94,3 % Übereinstimmung mit zwei KI-Lesern; nicht als korrekt belegt
4	10 und 10b (mit Paketen A bis D und F, drei Gesprächen, Nebentest)	Was bietet der Markt schon, und hebt sich die Liste ab? Was ändert die Sicht des Betriebs (selbst filtern)?	Kernprodukt gibt es kostenlos; belegt ist nur ein Merkmalsunterschied; Eigenbau gegen kostenlose Dienste im Modell (Annahmen) nie günstiger (Modellkonstruktion); Nachfrage offen

Grenzen vorweg. Vor Iteration 10 gab es keinen Kundenkontakt (Entscheidung des Nutzers, 2026-10-29); dann folgten drei kurze Telefonate (Hinweise, keine Stichprobe). Ob jemand für eine solche Liste zahlt (A1, A15), ist ungeprüft. Alle Messungen gelten für eForms-Bekanntmachungen (ab Herbst 2023) oberhalb der EU-Schwelle, Haupt-CPV 909, Deutschland.

Kleines Glossar (Kennungen erscheinen in den Tabellen wieder).

Begriff	Bedeutung
Los	Teil einer Ausschreibung mit eigenem Zuschlag; Einheit der Liste
Ende der Grundlaufzeit / Höchstende	Ende der ersten festen Laufzeit / Ende einschließlich aller Verlängerungsoptionen

Begriff	Bedeutung
Vergleichswert	Ende der Grundlaufzeit nach einer vorab committeten, neutralen Definition, gelesen von zwei KI-Lesern
Kriterien K, V, W, X, Y, Z, D	Schwellen, je Iteration neu vergeben und vor dem Ergebnis festgelegt; gelten nur in der genannten Iteration (V Iteration 3 und 9, W Iteration 4, 10 und 10b, X Iteration 5, Y Iteration 6 und 7, Z Iteration 8, D Paket D)
L, N, M mit Zahl	Nummer eines Loses in der Stichprobe (L Iteration 6 bis 8, N Iteration 9, M Iteration 10b), z. B. M54
Regeln 1a, 1b, 6 bis 10	Leseregeln der Liste; 1b: „das Enddatum der Bekanntmachung ist schon das Höchstende"; 6 bis 10 aus Iteration 9
Stufe A bis F	Güteklasse je Listeneintrag (Herkunft des Endes): A aus Text gelesen oder unauffällig, B berechnet, C ohne Angabe, D unbestimmbar, E geschätzt, F kein Ende
diskordant	Liste und Vergabeweiser weichen um mehr als einen Tag ab oder eine Seite hat kein Datum
Wilson	95-%-Konfidenzintervall für einen Anteil
Zuschlagsbekanntmachung	Veröffentlichung, dass ein Auftrag vergeben wurde (an wen, für welche Laufzeit)
naive Referenz (Baseline)	einfache Vergleichsregel, die eine Prognose übertreffen muss, um etwas zu taugen
Make or Buy	Entscheidung „selbst bauen oder kaufen/abonnieren"
Push-Nachricht	Meldung, die von selbst im Arbeitswerkzeug (Teams, E-Mail) ankommt

1. Business Understanding im Überblick

Kurzfassung für den Dozenten. Quellen: `docs/business.md` *§6 bis §8,* `reports/wettbewerbsbild_oberpfalz.md`*. Angaben aus Web-Recherche eines KI-Agenten und eines KI-Gutachtens sind nur dort „geprüft", wo* `docs/business.md` *es vermerkt.*

Rahmen: die Entscheidung eines Gebäudereinigungsunternehmens (Wunsch des Nutzers). Ein Betrieb, der für Kommunen und Behörden bietet, fragt: *Selbst bauen, kostenlos nutzen oder abonnieren?* (Make or Buy). Kosten und Break-even rechnen wir nur mit Annahmen (Aufwand, Stundensatz, Pflege nicht gemessen; `reports/make_or_buy.md`); dass Eigenbau gegen kostenlose Dienste „nie günstiger" ist, ist eine Modellkonstruktion und keine Messung. Ob es einen tragfähigen Business Case gibt, prüften wir mit einem vorab festgelegten Auswahlbogen (`docs/business_case_auswahl.md`).

Ergebnis der Business-Case-Prüfung (Fakten, 2026-11-06 bis 11-09).

- *Auswahlbogen:* Acht Kandidaten (K-A bis K-H) wurden nach sieben Kriterien mit je 0 bis 2 Punkten bewertet (höchstens 14; Schwelle 8, vorab). Die höchste Summe war 7 (K-A, Amtsinhaber-Quote), also unter 8: **kein tragfähiger Business Case.** Die Kriterien wurden festgelegt, nachdem die Recherchen vorlagen (Bestätigungsgefahr).
- *Test K-A abgebrochen:* Nach der vorab festgelegten Regel (Abbruch unter 30 verwertbaren Paaren) hatten nur 23 von 52 Paaren einen Zuschlag des Nachfolgers.
- *Nachtrag K-J* (Push in Teams, Outlook, Planner per Power Automate; Evaluation 2026-11-08/09; Quellen, gelesen 2026-11-06, in Abschnitt 11 und `docs/quellen.md`; Details `docs/business_case_auswahl.md`): Den Ablauf gibt es schon kostenlos (TED-Suchprofile mit E-Mail-Alarm und RSS, Vergabeweiser-Alerts, Weiterleitung per Standard-Flow); die HTTP-Aktion in Power Automate ist Premium (13 € je Nutzer und Monat; laut Microsoft-Seite zu Flows mit Dienstprinzipal, indirekte Aussage). Das Problem „Suchaufwand" ist in den drei Gesprächen nicht belegt; im Datensatz ergeben sich etwa 13 bis 19 Treffer pro Jahr und Profil (Profile erfunden). Punkte K1 bis K7 (Evaluator): 0 (wohlwollend 1), 0 (wohlwollend 1), 1, 1, 2 (Schätzung), 1, 0; Summe streng 5, wohlwollend 7 von 14, K7 = 0: **Ergebnis unverändert.** Billiger Test (nicht durchgeführt), Schwelle vorab am 2026-11-09: mindestens 2 von 3 Betrieben nutzen Teams oder Planner aktiv, nennen mindestens 1 Stunde pro Woche für Sichten und Übertragen und übertragen heute von Hand; sonst wird K-J verworfen.
- *Offen:* Der billige Test (eine Stunde Alarm-Weiterleitung bauen, drei Anrufe mit vorab festgelegter Schwelle) ist vorbereitet, **nicht durchgeführt**; Hypothesen H1/H2 (Annahmen A21, A22) ungeprüft; Wizard-of-Oz-Blatt (`docs/wizard_of_oz_blatt.md`) nicht durchgeführt.

Wie gehen Betriebe heute vor (Fakten).

- Zugang zu Ausschreibungen: kostenlos über den Bekanntmachungsservice oeffentlichevergabe.de, Suchprofile auf TED und IHK-Dienste; kostenpflichtig über Dienste wie subreport (84 bis 198 € pro Monat), DTAD (Vertrieb) oder evergabe.de (83 € pro Monat) (`docs/business.md` §8.1). 63 % aller Vergaben 2024 nur nach Preis.
- Gespräche (n = 3, Hinweise; `docs/business.md` §8.9): Ein Betrieb mit etwa 120 Beschäftigten zahlt knapp 1.500 € pro Jahr für DTAD; ein Betrieb mit 15 Beschäftigten zahlt für kein Portal. Ob mitgeboten wird, entscheiden Entfernung, Personal und Kapazität; Vertragsenden bei anderen kennt keiner. Die Vergabestelle (Oberpfalz) verlängert „fast immer", wenn eine Option im Vertrag steht (n = 1).

Konkurrenz mit der Funktion „auslaufende Verträge" (Fakten, Stand 2026-11-05).

Anbieter	Was er zeigt	Preis	Stand der Prüfung
Vergabeweiser	Verträge, die in 12 Monaten enden (1.005 in Gebäudereinigung), mit Zuschlagsempfänger, Angebotszahl, Optionen; nach eigener Angabe auch unterhalb der EU-Schwelle (von uns nicht gemessen); kostenlose API und Marktzahlen	kostenlos	Seite und API von uns geprüft und genutzt

Anbieter	Was er zeigt	Preis	Stand der Prüfung
AusschreibungsRadar	rund 26.000 Aufträge mit Ende in 1 bis 18 Monaten, „verlängerbar" markiert, geschätzter Ausschreibungsmonat; ab Starter (29 €) volle KI-Eignungsanalyse, ab Business (79 €) Match-Score, Bid/No-Bid-Check und Wettbewerber-Tracking, Professional 149 €	0 bis 149 € pro Monat	Seiten und Preisseite von uns gelesen; Nebentest mit 2 sicher zugeordneten Losen
aufträge.io, subreport, DTAD	aufträge.io: 43.373 Verträge mit Ende in 12 Monaten (auf Anfrage); subreport, DTAD: Ausschreibungsdienste, eine Funktion für auslaufende Verträge in unseren Quellen nicht belegt	subreport 84 bis 198 € pro Monat, DTAD knapp 1.500 € im Jahr	Recherche, Gespräch 1

Beide geprüften deutschen Anbieter schreiben selbst, dass der Auftraggeber entscheidet, ob und wann neu ausgeschrieben wird. Ein Profilfilter („Eignung", „Match") wird bei AusschreibungsRadar schon angeboten (`docs/business.md` §8.2).

Fachliches Erfolgskriterium (nachträglich formuliert, begründete Setzung)

> **Einordnung.** Ein fachliches Kriterium gab es seit 2026-11-04 (`docs/business.md` §7.1): Nutzen = „Der Betrieb kann Angebot, Referenzen und Personal gezielt vorbereiten, statt Bekanntmachungen dauernd zu beobachten"; Schwelle = Terminfenster ±3 Monate in mindestens 60 % und 10 Prozentpunkte über der naiven Referenz (vorab, vor dem Backtest). Es trug nicht (28,8 %). Die Schärfung unten wurde **erst nach Iteration 10** formuliert, ohne Kundenkontakt vor dem Projekt; sie ist eine begründete Setzung und kein vorab festgelegtes Kriterium.
>
> **Nutzen (Setzung).** Die Liste auslaufender Verträge ist ein Produkt, wenn ein Reinigungsbetrieb, der für Kommunen und Behörden bietet, damit früher als bisher weiß, wo sich ein Angebot vorzubereiten lohnt, und dafür zahlt.

Bedingung (Setzung)	Begründung	Ergebnis (Stand 2026-11-05)
(i) Ein belegter Unterschied zur kostenlosen Konkurrenz	Wer dieselbe Information kostenlos bekommt, zahlt nicht	**Merkmalsunterschied, kein Qualitätsvorteil:** Ende je Los und der Grundlaufzeit; auf zwei Stichproben in rund 10 % der Lose, davon in 10b 11 von 15 Höchstende oder Losebene
(ii) Zahlungsbereitschaft von mindestens 2 von 3 größeren Betrieben über 50 € im Monat	ein Preis oberhalb des Free- und Starter-Niveaus der Konkurrenz	**nicht geprüft, in den Hinweisen gespalten:** nur ein größerer Betrieb erreicht; er nannte keinen Betrag für die Liste, für Wettbewerbsdaten „klang nach 50 bis 100 €" (Einschätzung des Nutzers); der Kleinbetrieb „für gar nichts"
(iii) Ausreichende Abdeckung der Zielregion	Fehlt der Vertrag in der Liste, hilft sie nicht	**Lücke der TED-Basis (Paket B, Hinweis):** Im Bekanntmachungsservice stehen 32 von 120 Oberpfälzer Reinigungsverfahren (26,7 %, Wilson 19,6–35,2 %) nicht auf TED; „national" heißt „nicht auf TED gefunden". Wert gegen die Schwelle nicht geprüft, B1 nicht entscheidbar.

Gesamturteil zum fachlichen Erfolgskriterium (Stand 2026-11-05). (i) teilweise erfüllt (Merkmalsunterschied, kein Qualitätsvorteil); (ii) nicht prüfbar (nur ein größerer Betrieb erreicht); (iii) nicht entscheidbar (rund ein Viertel nicht auf TED, Wert gegen die Schwelle nicht geprüft). **Das Produkt als eigenes Angebot ist nicht belegt.** Die Sicht des Betriebs (Paket D, unten) ändert das nicht: Sie liefert eine Kostenrechnung unter Annahmen und einen Export, aber keinen Nachfragebeleg.

Entscheidung gegen den gebauten LLM-Profilfilter. Der Filter (Eignung eines Loses per Sprachmodell) wurde nicht verworfen, sondern nach einem billigen Test zurückgestellt: dem Wizard-of-Oz-Blatt (fünf echte laufende Oberpfälzer Lose, vom Betrieb zu bewerten; vorbereitet, **nicht durchgeführt**). Gründe: AusschreibungsRadar bietet KI-Eignungsanalyse ab 29 € und Match-Score ab 79 € schon; die Gesprächsgründe Personal, Kapazität und Bürokratie sind aus TED-Feldern kaum ablesbar; erst bauen und dann prüfen wiederholte den Fehler aus dem Marktgate (Lernpunkt unten).

Risiken

Risiko	Beleg (Fakt)	Gegenmaßnahme / Stand
Markt: Konkurrenz kostenlos	Vergabeweiser zeigt 1.005 Reinigungsverträge kostenlos; AusschreibungsRadar ab 0 € (A2 widerlegt)	eingetreten; Zyklus 4; Positionierung in einer Nische ungeprüft
Nachfrage	3 Gespräche, gespalten; A1, A15 ungeprüft; Datenübergabe nicht erfragt	offen; keine Nachfrageaussage
Zielgruppe ohne IT	Kleinbetrieb ohne Verwaltungssystem (Gespräch 2); nur rund ein Drittel mit Branchensoftware (sekundär); Importschnittstellen nicht geprüft	Export hilft nur Betrieben mit Zielsystem; Kurztest vorbereitet, nicht durchgeführt
Pflege	Eigenbau 5 bis 50 Stunden je Jahr (Annahme); TED-Felder, Schema und Dienste ändern sich	in Rechnung als Annahme; nicht gemessen
Daten	TED nur oberhalb der EU-Schwelle (über alle Branchen 88 % der Vergaben darunter); 25,4 % der Oberpfalz-Lose ohne Ende; Zuschlagswert nur bei 47,7 %; die meisten Vorgänger heutiger Neuausschreibungen vor eForms (55 von 68)	Paket B: Lücke von rund einem Viertel im Bekanntmachungsservice, Erweiterung nur als Ausblick
Listenfehler	12 Lose (0,13 %), bei denen das Dauerfeld die Option schon enthält; bei 1 von 10 übereinstimmenden Losen beide Quellen falsch	Liste eingefroren; als offene Grenze genannt (Abschnitt 7)

Risiko	Beleg (Fakt)	Gegenmaßnahme / Stand
KI-Methode	Regeln, Leser und Evaluator gleiche Modellfamilie; Menschenprüfung nur 14/15 (Kommilitone), nicht an den 15 diskordanten Losen	offengelegt; zweite Modellfamilie und Menschenprüfung fehlen
Recht	TED-Lizenz laut Rechtsseite frei wiederverwendbar (vor Abgabe zu bestätigen); Vergabeweiser CC BY 4.0 (Nennung); Auftragnehmernamen können bei Einzelunternehmern personenbezogen sein (Vorprüfung: 4 von 47 Namen ohne Rechtsform; Export auch ohne Namen); kein Scraping, nur einzelne Seiten von AusschreibungsRadar, `robots.txt` beachtet	Wortlaut der TED-Rechtsseite vor Abgabe selbst bestätigen

Mehrwert und Positionierung (Deutung, n = 3). Der größere Betrieb sähe Nutzen in einem frühen Hinweis, würde aber eher für Wettbewerbsdaten zahlen (aktueller Auftragnehmer, alte Preise); der kleine will nichts zahlen. Aus TED allein sind diese Daten nur teilweise zu bekommen (130 Oberpfalz-Lose: Auftragnehmer 99,2 %, Zuschlagswert über 1 € 47,7 %, Angebote 60,8 %, alle drei 24,6 %).

Competitive Edge, ehrlich. *Was bleibt:* ein Merkmalsunterschied auf Los- und Definitionsebene (rund 10 % der Lose auf zwei Stichproben, Abschnitt 5), ein offen dokumentiertes Prüfverfahren und der Backtest, dass ein fester Abstand den Termin nicht vorhersagt. *Was nicht bleibt:* Preis, Daten (offen), Wettbewerbsbild, Terminprognose; Vergabeweiser nennt nach eigener Angabe auch Verfahren unterhalb der EU-Schwelle, wir haben das nicht gemessen. *Ausblick, kein Vorteil:* Daten unterhalb von TED (Zeile (iii)). *Nicht behauptet:* dass die Liste genauer ist als Vergabeweiser, dass Vergabeweiser falsch liest, dass ein Marktvorteil besteht oder dass Betriebe die Liste nachfragen oder bezahlen.

Perspektive des Betriebs (Make or Buy; Paket D). Rahmen und Ergebnis stehen oben; Modell und Szenarien in Abschnitt 5. Im Basismodell ist Eigenbau gegen Vergabeweiser und AusschreibungsRadar Starter nie günstiger (Modellkonstruktion, keine Messung), gegen ein Abo wie DTAD nur im Szenario „niedrig"; symmetrisch gerechnet 1,0 bis 12,0 Jahre. *Deutung:* „Keine Abo-Kosten" trägt nicht, weil kostenlose Wege existieren und der Eigenbau Betriebs- und Pflegekosten hat.

Lernpunkt: Die Konkurrenz wurde erst spät gesehen (Prozessfehler)

- **Fakten.** Der Projektplan sah früh vor, die Wettbewerber zu sichten (G1.1); sie blieb offen. Am 2026-10-24 fanden zwei Suchen von Claude keinen deutschen Dienst für auslaufende Verträge (`docs/business.md` §6). Am 2026-10-29 entschied der Nutzer gegen Kundenkontakt; G1.1 wurde erst am 2026-11-05 erledigt.
- **Deutung und Konsequenz.** Ein Prozessfehler, nicht nur ein Suchfehler der KI: Keine Stelle erzwang G1.1 vor der Modellierung. Phase 1 braucht ein **Marktgate vor der Modellierung** (Wettbewerber gesichtet und dokumentiert; jede Streichung eines Plan-Punktes braucht eine Ersatzprüfung). Kosten: Zyklus 4; die Iterationen 5 bis 9 arbeiteten an einer Liste, die es kostenlos gibt.

2. Zyklus 1: Zuordnung zum Vorgänger (Iteration 1 bis 4)

Business Understanding: Kandidaten für eine Nische waren Gebäudereinigung, IT-Wartung, Winterdienst, Sicherheit, Kantine; Kriterium war genug Zuschläge mit Laufzeit. Datenbasis: TED Search API v3, Rohdaten unverändert in `data/raw`.

Iteration (Datum)	Frage	Kriterium vorab	Ergebnis (Fakten)	Entscheidung
1 (10-22)	Sind die Daten für eine Nische machbar?	genug Zuschläge mit bestimmbarer Laufzeit	Laufzeitende bei Gebäudereinigung 90,0 % bestimmbar (streng 80,9 %); Verlängerungsfeld BT-58 nur 18,9 % befüllt (A5 widerlegt); Wertfelder mit Platzhaltern (A6 widerlegt)	Gebäudereinigung vorläufig; weiter
2 (10-23)	Genügen Auftraggeber + CPV, um einen neuen Auftrag dem Vorgänger zuzuordnen?	K2 ≥ 80 %	K2 = 5/30 = 16,7 % (Wilson 7,3–33,6); 629 abgelaufene eForms-Verträge; Median-Laufzeit 12 Monate	Zuordnung über das Objekt (Adresse, Titel) versuchen
3 (10-24/25)	Trägt eine Objekt-Regel?	Sichtbarkeit eines Vorgängers (V1), Präzision (V2) ≥ 80 %, Trefferquote (V3) ≥ 60 %	V1 63,3 %, V2 45,8 %, V3 28,9 %; auf Entwicklungsdaten hielt Claude 10–11 von 12 Vorschlägen für plausibel, im Test 11 von 24 korrekt	Regel verworfen; letzter Versuch auf neuen Testdaten
4 (10-25 bis 10-30)	Verbessert eine erweiterte Regel auf neuen Testdaten?	W2 Präzision, Mindestzahl 25 Vorschläge; W3 Trefferquote ≥ 60 %; W4 Zweitprüfung des Nutzers ≥ 85 %	W2 17/19 = 89,5 %, aber nur 19 Vorschläge; W3 56,7 %; W4 13/20 = 65 %	**Idee anpassen:** keine weitere Zuordnungsregel; Vertragsliste aus den Zuschlägen selbst

Deutung. Große Auftraggeber vergeben viele Verträge parallel; die Kennung reicht nicht. Vor eForms liefert `REF_NOTICE` die Laufzeit (A11: 25/30).

Phasen: Business Understanding und Data Understanding (Iteration 1 und 2: Nische, Machbarkeit), Data Preparation und Modeling (3 und 4: Zuordnungsregel), Evaluation (Blindprüfung, Handsuche), Deployment entfällt; Rücksprung innerhalb des Zyklus nach jeder verfehlten Schwelle.

Für Laien: Wir wollten einen neuen Auftrag automatisch seinem Vorgänger zuordnen. Das gelang auch mit besserer Regel nicht zuverlässig genug, also haben wir diesen Weg aufgegeben.

3. Zyklus 2: Terminprognose (Iteration 5)

Iteration (Datum)	Frage	Kriterium vorab	Ergebnis (Fakten)	Entscheidung
5 (10-30 bis 11-04)	Sagt „Höchstende − 6 Monate“ (R1) den Termin der Neuausschreibung voraus?	Treffer = Fenster ±3 Monate; X3: ≥ 60 % und ≥ 10 Prozentpunkte über der Baseline R0 (Ende der Grundlaufzeit − 6 Monate); Schwelle vor jeder Berechnung festgelegt	52 von Hand bestätigte Paare (Zweitprüfung 61/67 = 91,0 %, mit KI-Hilfe, nicht als unabhängig gewertet): R1 28,8 % (Wilson 18,3–42,3), R0 17,3 %; 20 Neuausschreibungen kamen mehr als 3 Monate früher, 17 später	**Idee anpassen:** keine Terminprognose; Produktkern ist die Vertragsliste mit Enddaten

Phasen: Business Understanding (Prognoseziel und Schwelle vorab), Data Preparation (Zuschlagstabelle), Modeling (Regel R1 gegen Baseline R0), Evaluation (52 Paare, Zweitprüfung), Deployment entfällt.

Für Laien: Wir haben getestet, ob ein fester Abstand zum Vertragsende den Termin der Neuausschreibung trifft. Er traf nur in 28,8 % der Fälle (gefordert: 60 %); eine einfache Vergleichsregel kam auf 17,3 %.

Data Preparation: Zuschlagstabelle je Los (`src/prepare/vertragsliste.py`) mit Ende der Grundlaufzeit, Höchstende und Herkunft; Leakage vermieden (nur Wissen zum Zeitpunkt des Vorgänger-Zuschlags). *Deutung:* Der Termin ist zweigipflig verteilt; ein fester Abstand trägt nicht; die Vergabestelle stützt das (Verlängerung ist der Normalfall).

4. Zyklus 3: Qualität der Vertragsliste (Iteration 6 bis 9)

Iteration (Datum)	Frage	Kriterium vorab	Ergebnis (Fakten)	Entscheidung
6 (11-04)	Wie genau ist der Prototyp (Oberpfalz, 146 Lose, Stufen A–F)?	Y1 Ende der Grundlaufzeit ≥ 90 % an 60 Zufallslosen (Prüfung durch den Nutzer); Y3 Abdeckung ≥ 80 %	Y1 54/60 = 90,0 % laut Auswertung, 53/60 = 88,3 % nach Fehler L60; Höchstende 91,7 %; Abdeckung 79,7 % (damalige Fassung). Die Vorlage zeigte den Listenwert (Verankerung, vom Evaluator gefunden)	Zurück zu Phase 3: Regel 1b, neue Stichprobe
7 (11-04)	Behebt Regel 1b den Fehlertyp „Enddatum ist schon Höchstende“?	Y1 ≥ 90 %, Y1r ≥ 12/15 Regelwirkungs-Lose; vorab: Y1 zwischen 70 und 90 % → kein dritter Regelversuch	Y1 36/47 = 76,6 % (Wilson 62,8–86,4), Y1r 8/15, Höchstende verfehlt. Mischmaß aus Listen- und Prüfungsfehlern (bei 45 von 47 Losen schrieb die Nachprüfung dasselbe Feld ab)	Abschluss mit diesem Stand; Ende „laut Bekanntmachung“, Höchstende nur Hinweis
8 (11-04/05)	Bestätigen zwei KI-Leser die Liste?	Z0 Leser untereinander ≥ 90 %, Z1 bis Z4 (Liste gegen Vergleichswert, Regelwirkung, Höchstende, Kontrolle)	Z0 94/95; Z1 77/80 = 96,2 %; Z2 14/15 (bei einheitlichem Maßstab 11/15, verfehlt); Z3 75/80 und 67/72; Z4 10/10. Neue Listenfehler: Lose ohne Zuschlag, Übertragung von Werten, „3 Jahre mit Option“	Weiter (Projektabschluss), eingeschränkt: Leser nicht unabhängig, nicht von Menschen bestätigt
9 (11-05)	Beheben Regeln 6 bis 10 diese Fehler; hält die Liste auf einer neuen Stichprobe (Seed 20261109, 110 Lose)?	V1 ≥ 90 %, V2 bis V8 (u. a. Höchstende V4, Lose ohne Zuschlag V7, Verfahren V8)	Liste 9.325 statt 9.915 Lose; V1 66/70 = 94,3 % (Wilson 86,2–97,8); V2 28/30; V3 66 gegen 65 von 70 (alte Fassung); V5 110/110; V6 Kommilitone 14/15. **Verfehlt:** V4 (87,1 % bei Schwelle 90 %), V7 (Los N51); V8 teilweise	Weiter, eingeschränkt: Fassung 9 wird Prototyp, Höchstende nur Hinweis; „V1 bis V8 erfüllt“ wird nicht behauptet

Phasen: Rücksprung zu Phase 3 und 4 (Regeln 1b, 6 bis 10), Evaluation je Iteration an neuen Stichproben, Deployment: Prototyp der Webseite (Abschnitt 6).

Für Laien: Wir haben die Liste der Vertragsenden mehrfach an Stichproben geprüft und die Leseregeln verbessert. Zuletzt stimmen 66 von 70 Verträgen mit dem Vergleichswert überein; „fehlerfrei“ ist das nicht belegt.

Abdeckung (Zähler und Nenner, an einer Stelle). Quelle: `data/processed/vertragsliste_909.csv` (Fassung 9) und `reports/vertragsliste_iteration9.md` , nachgerechnet.

- **Alle Lose:** 6.803 von 9.325 haben ein Ende der Grundlaufzeit, **rund 73 %** (72,95 %); 2.522 Lose (27,0 %) haben keines.
- **Letztes Jahr (X4):** Unter den Losen aus Zuschlägen, veröffentlicht 2025-10-01 bis 2026-09-30, haben 2.783 von 3.503 ein Ende, **79,4 %** (Wilson 78,1–80,8; Schwelle 80 % knapp verfehlt). Der Anteil schwankt nach Halbjahr zwischen 63,6 % und 80,7 %; das letzte Jahr liegt deshalb über dem Gesamtwert.
- **Lose ohne Ende:** über alle Lose 27,0 %, im letzten Jahr 20,6 %.

Deutung. Die Fassung 9 ist auf der Stichprobe zu 94,3 % mit dem Vergleichswert identisch (alte Fassung 92,9 %, bloßes Feld 90,0 %). Der Nutzen der Regeländerung ist nicht gesichert: Die Stichprobe trennt die Fassungen kaum, der Vergleichswert ist teilweise zirkulär, V5 zeigt vor allem gleiche Anweisung und gleiche Rohtexte. *Grenzen:* gleiche Modellfamilie von Regel, Leser und Evaluator; V6 mit 15 Losen dünn. Details: `docs/iterationen.md`, `reports/evaluation_iteration7.md` bis `_iteration9.md`.

5. Zyklus 4: Business Understanding und Wettbewerb (Iteration 10 und 10b)

Anlass (2026-11-05, nach Iteration 9): Der Dozent verlangt mehr Gewicht auf Business Understanding; die Sichtung der Wettbewerber war nie erfolgt (Abschnitt 1). Abweichend von „keine weitere Iteration" beschloss der Nutzer einen Rücksprung zu Phase 1. Stichprobe und Vergleichswert der Iteration 9 dienten als fester Maßstab.

Phasen: Rücksprung zu Phase 1 (Business Understanding), dann Data Understanding (Vergabeweiser-API, Bekanntmachungsservice), Evaluation (10b, Pakete), Deployment nur als Veranschaulichung (Abschnitt 6).

Für Laien: Wir haben geprüft, was es am Markt schon gibt und ob sich mit der Liste ein Geschäft machen lässt. Ergebnis: Die Liste gibt es kostenlos, ein Geschäft ist nicht belegt.

Iteration 10: Business Understanding und Wettbewerber. Recherche (KI-Agent plus KI-Gutachten aus BWL-Sicht, einzelne Seiten von Claude nachgelesen): Vergabeweiser bietet eine kostenlose Liste auslaufender Verträge samt API, AusschreibungsRadar eine günstige; **A2 („es gibt keinen deutschen Dienst") ist widerlegt.** Das Gutachten hielt das Kernprodukt „Liste" für nicht tragfähig (`docs/business.md` §8.4, §8.5). Gespräche (W5, Leitfaden vorab): neun Anrufe, drei Stellen erreicht (zwei Reinigungsbetriebe, eine Vergabestelle); Notizen ohne Namen. Zahlungsbereitschaft zeigte sich nur für Wettbewerbsdaten; die Vergabestelle bestätigt, dass das Vertragsende kein Neuausschreibungstermin ist. n = 3, Hinweise.

Vorgehen. Vergabeweisers API (Rohantworten in `data/raw/vergabeweiser_20261105/`) liefert das Vertragsende je Verfahren, nicht je Los; die Zuordnung eines Loses lief per Skript ohne Handentscheid. **Hypothese** *(vorab, vor dem Abruf)*: Auf den 70 Zufallslosen der Iteration 9 stimmt Vergabeweiser seltener mit dem Vergleichswert überein als die Liste (66/70). In 10b (Seed 20261112, 160 neue Lose mit Listenende) lasen zwei KI-Leser nur die diskordanten Lose, ohne Quellenangabe, nach der neutralen Definition; Hypothese vorab: die Liste trifft häufiger, und der Unterschied reicht über die Granularität hinaus.

Kriterium (vorab)	Schwelle	Ergebnis (Fakten)	Urteil
W1 (Iteration 10, 70 Lose)	Differenz Liste − Vergabeweiser ≥ 5 Lose	Liste 66/70, Vergabeweiser 58/70, +8, exakter Test p = 0,0078; Ursachen der 8: Losebene 4, Höchstende statt Grundlaufzeit 2, fehlender Wert 1, 2 Tage 1; Basisregel „Feld EndDate" 63/70	formal erfüllt, überwiegend Los- und Definitionsunterschied; zählt Vergabeweisers Verfahrensdatum als richtig, wenn es irgendeinem Los entspricht, sinkt die Differenz auf +4
W8a (10b)	≥ 16 Lose (10 %) und p < 0,05	15 von 160 Losen diskordant; Leser 15/15 einig; Liste 15/15, Vergabeweiser 0/15; +15, p = 0,0001	**formal verfehlt, rechnerisch unerreichbar** (Schwelle aus der Diskordanzrate der Iteration 10 übernommen, Fehler der Vorab-Festlegung)
W8b (10b)	≥ 8 Lose und p < 0,05, Vergabeweiser gilt auch bei Datum irgendeines Loses desselben Verfahrens als richtig	+10, p = 0,0020	erfüllt, schwach aussagekräftig
W7 Nebentest AusschreibungsRadar	beschreibend (Seed 20261111, 15 Lose)	nur 2 von 15 sicher zugeordnet, beide wie Liste und Vergleichswert	keine Aussage zur Genauigkeit möglich

Einordnung der 15 diskordanten Lose (Evaluator, je Los am Rohtext). Höchstende statt Grundlaufzeit 7 (eine einzige Textvorlage), Losebene 4, Zuordnungsfehler der Pipeline 1 (M54), Ursache offen 2, mehrdeutig 1. Zählt das Höchstende für Vergabeweiser als richtig, bleiben 3 : 0, p = 0,25. Beide Stichproben zusammen: nur die Liste richtig bei 23 von 230 Losen = 10,0 % (Wilson 6,8–14,6 %).

Deutung. Der Unterschied zugunsten der Liste ist ein **Merkmalsunterschied** (Ende je Los, Grundlaufzeit statt Höchstende), kein belegter Qualitätsvorteil beim Lesen: Liste und Vergabeweiser nutzen dasselbe TED-Feld, gemeinsame Fehler bleiben unsichtbar, die Leser stammen aus derselben Modellfamilie wie die Regeln.

Pakete A, C, F und B (Nachträge, Entscheidung des Nutzers 2026-11-05).

- **A, Wettbewerbsbild aus TED** (`reports/wettbewerbsbild_oberpfalz.md`): Zahlen siehe Abschnitt 1; Handabgleich von 5 Losen 5 von 5. Deutung: Ein Wettbewerbsbild aus TED allein ist nur zu etwa einem Viertel der Lose vollständig.
- **C, Ursachen der Lücken** (`reports/stufe_f_ursachen.md`): Die 33 Lose ohne Ende haben alle keine Laufzeitfelder im XML. Dabei fand sich der Fehlertyp „Dauerfeld enthält die Option schon": **12 Lose in 5 Bekanntmachungen, 0,13 % der 9.325 Lose**; zwei Fälle am Rohtext bestätigt.
- **F, Optionsanalyse** (`reports/optionsanalyse.md`): Bei belegter Option (n = 24 von 52 Backtest-Paaren) lag die Neuausschreibung in 70,8 % zwischen dem Ende der Grundlaufzeit und dem Höchstende (Wilson 50,8–85,1). Hinweis, kein Beleg.

- **B, Abdeckung unterhalb der EU-Schwelle (A3, Oberpfalz)** (`reports/oeffentlichevergabe_test.md` , `_robustheit.md`). *Hypothese und Kriterien (vorab, `0e83dfa`):* Mindestens ein Drittel der Oberpfälzer Reinigungsverfahren (Haupt-CPV 909) liegt unterhalb der EU-Schwelle (B1 ≥ 33 %); B2 bis B5: Feldabdeckung, Überlappung mit der Liste, Handabgleich von 5 Verfahren, Machbarkeit. Daten: OCDS-Jahresdateien des Bekanntmachungsservice 2024 bis 2026 (CC0, 626.620 Datensätze), ohne Kennzeichen für die Schwelle; „national" heißt „nicht auf TED gefunden".
- *Erste Auswertung (Filter NUTS-3-Code am Lieferort):* 84 Verfahren, alle auf TED, 0 national. *Artefakt:* Nationale Verfahren tragen am Lieferort zu 71,2 % nur den NUTS-1-Code „DE2" (EU-Verfahren zu 92,4 % einen NUTS-3-Code); der Filter schloss sie aus. Die erste Auswertung („B1 deutlich verfehlt") ist nicht gültig.
- *Ergebnis (Postleitzahl, Ortsliste):* 32 von 120 Verfahren nicht auf TED = 26,7 % (Wilson 19,6–35,2 %; Jahreswerte 13 bis 45 %). **B1 ist nicht entscheidbar**, das Intervall schließt 33 % ein. 62 von 64 Bekanntmachungen der Liste stehen im Datensatz.
- *Deutung:* Rund ein Viertel der Reinigungsverfahren im Bekanntmachungsservice fehlt auf TED: ein Hinweis auf eine Lücke der TED-Basis und ein Argument für die Erweiterung als Ausblick, **kein belegter Vorsprung**. A3 bleibt ungeprüft; die Aussage der Vergabestelle (n = 1) ist weder bestätigt noch widerlegt. *Lernpunkt:* Eine Null ist ein Verdachtsmoment, kein Ergebnis.
- *Grenzen:* „National" ist nicht „unterhalb der Schwelle"; Ortsregeln nicht von Hand geprüft; B2 und B4 stehen aus.
- **D, Perspektive des Betriebs (Make or Buy, Datenübergabe)** (`docs/business.md` §9; Stand: **Test vorbereitet, nicht durchgeführt**). *Vorab (2026-11-06):* H1 Ein befragter Betrieb mit Branchensoftware kann Treffer nicht ohne Abtippen übernehmen; H2 ein Betrieb könnte eine CSV mit festem Schema laden. D1 Modell mit Break-even; D2 Export mit Schema; D3 Test mit 1 bis 3 Betrieben durchgeführt; D4 „Datenübergabe ist relevant" nur, wenn H1 und H2 bei mindestens 2 von 3 bestätigt sind.
- *Fakten:* **D1 ja**, **D2 ja** (Schema 1.1, 26 Felder: CSV, CSV deutsch, JSON, dazu Variante ohne Auftragnehmer; vom Skript gegen das Schema validiert, in Excel nicht getestet), **D3 nein**, **D4 offen**.

Szenario (Annahme, Basismodell)	Kosten 3 Jahre	Break-even gegen DTAD	gegen Vergabeweiser, AusschreibungsRadar Starter	zusätzliche Aufträge in 3 Jahren (Marge 5 %)
Niedrig (20 h einmalig, 5 h/Jahr)	3.500 €	2,0 Jahre	nie	0,14
Mittel (60 h, 20 h)	12.000 €	nie	nie	0,48
Hoch (120 h, 50 h)	27.000 €	nie	nie	1,08

- *Deutung:* „Nie günstiger" ist eine Modellkonstruktion (Annahmen). „Keine Abo-Kosten" trägt nicht; ein Mehrwert müsste aus Funktion kommen. Die „zusätzlichen Aufträge" (Deckungsbeitrag 25.110 € je Auftrag, Median-Jahresumsatz 167.404 €) sind eine Größenordnung, kein Nutzenbeleg. *Grenzen:* Aufwände, Marge und Stundensatz nicht gemessen; keine Aussage zur Relevanz der Datenübergabe (D3 nein).
- **Nach Iteration 10b (2026-11-06 bis 11-09; Fakten, kein Erfolg behauptet).** (1) Business-Case-Auswahl mit vorab festgelegten Kriterien: kein tragfähiger Case (Abschnitt 1). (2) Demo Profil-Match mit Push-Vorschau, auf Wunsch des Nutzers nach dem Auswahlbogen gebaut (K7 = 0): Veranschaulichung der Datenübergabe, kein Business Case; Abnahmekriterien A1 bis A7 vorab, aber keine Hypothese zu Nachfrage oder Genauigkeit (`docs/demo_push.md`). (3) Live-Demo mit großem Datensatz und Filterlauf. (4) Video „Franz und die Glaskugel", Fassungen v1 bis v3. (5) Umbau der Folien auf zehn sichtbare Folien. (6) Prüfung von K-J (Abschnitt 1). Ergebnisse zum Anfassen: Abschnitt 6.

Abweichungen von der Vorab-Planung (offen). Zuordnungsweg 2 nach dem Trockenlauf ergänzt; Abrufskript nach DNS-Fehler angepasst; Nebentest W7 nach Beginn des Abrufs.

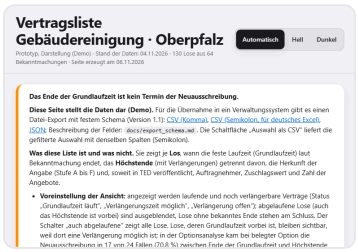
Entscheidung (2026-11-05, Nutzer): Weiter, Projektabschluss, eingeschränkt formuliert

- **Begründung.** W1 ist formal erfüllt, aber überwiegend Los- und Definitionsunterschied; W8a ist formal verfehlt wegen eines Fehlers der Vorab-Schwelle, W8b erfüllt. Nach der Vorab-Regel gilt „kein belegter Vorteil im definierten Maß", und das ist nicht als Gleichheit zu lesen. Befund: Merkmalsunterschied, kein belegter Qualitätsvorteil, Nachfrage offen.
- **Abweichung von der Vorab-Folge (offen begründet).** „W8a verfehlt → ‚kein Vorteil gegenüber Vergabeweiser' gilt weiter" wird nicht übernommen, weil sie der gemessenen Richtung widerspricht und die Schwelle unerreichbar war; „Die Liste ist genauer" wird ebenso wenig behauptet.
- **Geschäftlich.** „Liste als eigenes Produkt nicht tragfähig" (`docs/business.md` §8.4) bleibt bestehen; A2 bleibt widerlegt; A1, A3 und A15 bleiben ungeprüft. Weitere Grenzen: Abschnitt 7; das Protokoll der Leserläufe 10b liegt außerhalb des Repos.

6. Ergebnisse zum Anfassen: Vertragsliste, Webseite, Demo und Video

*Alle Dateien liegen im Repository. Sie veranschaulichen die Datenübergabe, sind **kein Business Case** (K7 = 0) und belegen weder Nachfrage noch KI-Genauigkeit noch einen Vorteil gegenüber den bestehenden Diensten. Screenshots: Abschnitt 11.*

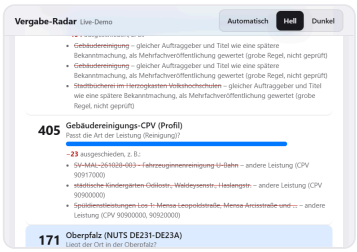
Ergebnis	Datei	Was es zeigt (Fakten)	Grenzen
Vertragsliste (Fassung Iteration 9)	`data/processed/vertragsliste_909.csv` (nicht im Git, erzeugbar), Export `docs/prototyp/export/` (Schema 1.1, `docs/export_schema.md`)	9.325 Lose; je Los Ende der Grundlaufzeit, Höchstende (nur Hinweis) und Herkunft in den Stufen A bis F (Glossar); 6.803 Lose mit Ende	Ende „laut Bekanntmachung“; „korrekt“ nicht belegt (Abschnitt 4)
Webseite	`docs/prototyp/vertragsliste.html`	Prototyp für die Oberpfalz (130 Lose aus 64 Bekanntmachungen, Stand 04.11.2026) mit Filtern (Suche, Auftragnehmer, Region, Status, Stufe, Zeitraum), CSV-Export der Auswahl, Hell/Dunkel/Automatisch	Prototyp, Darstellung; kein Produkt
Demo Profil-Match	`docs/demo_push.md` , `docs/demo/push_demo.html`	zwei erfundene Profile; Trichter der Filter; KI-Stufe urteilt „passt/unklar/passt nicht“ nur mit prüfbarem Zitat (7 gespeicherte Urteile); Teams-Karte und E-Mail nur als Vorschau, **nichts gesendet**	KI gegen Regel 13 von 14 (5 trivial, kein Mensch): keine Genauigkeit; Karten nie in echtem Teams gerendert
Live-Demo	`docs/demo/live_demo.html`	Beispieldatensatz (621 Bekanntmachungen, Auszug 150) und großer Datensatz (590 Bekanntmachungen, Bayern, 12 Monate bis 06.11.2026); erfundene Firma einstellen, Knopf „Filterung starten“ mit Filterlauf; KI-Urteile nur für P1/P2, sonst Stichwortregel; keine KI-Aufrufe, nichts gesendet	Beispiel: mit Frist-Filter 0, 1 und 2 Treffer für drei erfundene Firmen, keine Marktaussage; Vorgänger-Hinweis abgeschaltet (3 von 3 Auslösungen falsch)



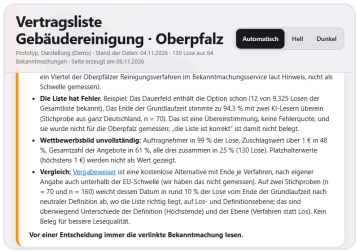
Webseite: Kopf und Hinweis zur Quelle



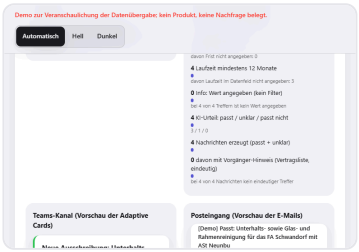
Push-Demo: Kopf, Profil P1 (erfunden)



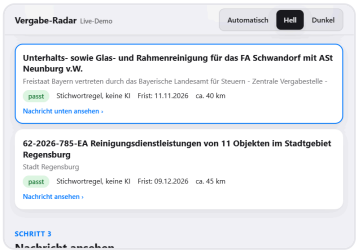
Live-Demo: Filterlauf mitten in der Animation



Webseite: Filter und Tabelle



Push-Demo: Teams-Vorschau und Posteingang



Live-Demo: Ergebnis für „Beispiel Cham GmbH (erfunden)“



Standbild, Szene „Ergebnis“ (Quellzeit 171 s)

Video „Franz und die Glaskugel“ (`docs/video/franz_und_die_glaskugel_szenen_0-5_v3.mp4` , Szenen 1 bis 5, rund 170 s; Quelle der Animation `docs/video/franz_und_die_glaskugel.html`).

- *Zweck:* Zusammenfassung des Projekts für den Vortrag, mit erfundenen Figuren (Franz, Bit, Prüfi). Veranschaulichung, kein zusätzlicher Beleg.
- *Herkunft:* Die Animation hat laut Nutzer ein Kollege KI-gestützt erstellt. Wir haben sie korrigiert: Zahlen gegen Belege geprüft (keine falschen Zahlen gefunden), zu starke Sätze eingeschränkt, Stimme und Export ergänzt; Liste der Korrekturen in `docs/video/README.md` .
- *Grenzen:* Stimme synthetisch (Piper, Thorsten-Voice); Figuren erfunden, Gespräche nachgestellt (es gab drei echte); vereinfacht (vier „Runden“ statt zehn Iterationen); Hörprobe durch den Nutzer **offen**.

7. Was wir empfehlen und was nicht

- **Rahmen: Sicht eines Gebäudereinigungsunternehmens.** Entscheidungsfrage des Betriebs: *Selbst bauen, kostenlos nutzen oder abonnieren?* Antwort nach unserem Stand (Deutung, unter Annahmen): zuerst die kostenlosen Wege nutzen (TED-Suchprofile mit E-Mail-Alarm, Vergabeweiser-Alerts, diese Liste als CSV); abonnieren nur für eine Funktion, die man braucht (im Gespräch genannt: Wettbewerbsdaten; Zahlungsbereitschaft in einem von drei Gesprächen); selbst bauen lohnt im Basismodell gegen kostenlose Dienste nie (Modellkonstruktion, Aufwand und Pflege nicht gemessen). Ergebnis der Business-Case-Prüfung: **kein tragfähiger Business Case** (höchste Summe 7 < 8; Test K-A nach der Vorprüfung abgebrochen, 23 von 52 Paaren; Push-Variante K-J streng 5, wohlwollend 7 von 14, K7 = 0). Nächster billiger Test (vorbereitet, **nicht durchgeführt**): eine Stunde Alarm-Weiterleitung bauen und drei Anrufe mit vorab festgelegter Schwelle.
- **Empfehlung.** Die Vertragsliste „Ende der Laufzeit laut Bekanntmachung" ist als Ausgangspunkt nutzbar; vor jeder Entscheidung die verlinkte Bekanntmachung lesen. Als eigenes Produkt empfehlen wir sie **nicht**, weil es das Kernprodukt kostenlos (Vergabeweiser) und günstig (AusschreibungsRadar) gibt. Weiterverfolgen ließe sich nur eine Nische (Wettbewerbsdaten, Datenqualität als Zulieferung, Vergabestellen), nach Gesprächen mit mehr Beteiligten.
- **Zulässige Aussagen.** „Zu 94,3 % identisch mit dem Vergleichswert zweier KI-Leser; an 15 Losen bestätigt ein Mensch (14/15); Höchstende nur Hinweis." Und: „Auf zwei Stichproben (n = 70 und n = 160) weicht Vergabeweisers Datum in rund 10 % der Lose vom Ende der Grundlaufzeit nach neutraler Definition ab, wo die Liste richtig liegt."
- **Nicht belegt.** Eine Terminprognose; „die Liste ist korrekt"; „Fehlerarten behoben und bestätigt"; „V1 bis V8 erfüllt"; ein Qualitätsvorteil gegenüber Vergabeweiser (und ebenso Gleichheit); Nachfrage, Zahlungsbereitschaft und Marktvorteil (A1, A15); Abdeckung unterhalb der EU-Schwelle (A3); Relevanz der Datenübergabe für Betriebe (D4 offen, H1/H2 ungeprüft); Nutzbarkeit des Exports in Excel oder Branchensoftware.
- **Offene Lücke Systemlandschaft.** In den drei Gesprächen wurde die Systemlandschaft nicht erfragt; der Test ist vorbereitet (Fragen im Wizard-of-Oz-Blatt, `docs/wizard_of_oz_blatt.md`).
- **Offene Grenzen der Liste.** Das Höchstende ist oft zu hoch (laut Evaluator in 7 von 11 Fällen) und nur ein Hinweis; Schuljahres-Verträge sind nicht tagesgenau; `unpublished` wird nicht erkannt; „Dauerfeld enthält die Option" (12 Lose, 0,13 %) und Textmuster wie M59 werden nicht gefangen. Die Zuordnung zu Vergabeweiser wurde nicht für alle 160 Lose von Hand geprüft; keine Menschenprüfung der 15 diskordanten Lose; keine zweite Modellfamilie. Die Demo Profil-Match belegt keine Nachfrage und keine KI-Genauigkeit (13 von 14, davon 5 trivial, ohne Menschenreferenz); Profile und Stichtag sind erfunden.

8. KI-Irrwege und ihre Prüfung

Die KI (Claude Code) hat Hypothesen, Regeln, Stichproben und Auswertungen mitgebaut. Die Fehler wurden vom Nutzer, vom Evaluator (eigener Subagent, nur Lesezugriff) oder von Claude selbst gefunden. Die sechs wichtigsten; die vollständige Tabelle mit allen Einträgen steht im Anhang B.

Datum	Irrweg	Bemerkt durch	Konsequenz
2026-10-25	Auf Entwicklungsdaten hielt Claude 10–11 von 12 Vorschlägen für plausibel, im Test waren 11 von 24 korrekt	Test auf neuen Daten	Regel verworfen; Testdaten strikt getrennt
2026-11-04	Iteration 6 und 7: Prüfvorlage zeigte den Listenwert (Verankerung); danach wurden Felder versteckt, und die Nachprüfung übernahm das Feld	Evaluator, Auswertung	Y1 nur als Mischmaß berichtet; Vorlage ohne Listenwerte
2026-11-05	Wettbewerber nicht gesichtet (G1.1), zwei Suchen fanden keinen Dienst	Recherche-Agent nach Hinweis des Dozenten	A2 widerlegt; Marktgate (Abschnitt 1); Zyklus 4
2026-11-06	Demo, Vorgänger-Hinweis (Titelähnlichkeit): nur an einem erfundenen Titel getestet; im großen Datensatz lagen alle 3 Auslösungen falsch	Prüfung am großen Datensatz (Claude)	im großen Datensatz abgeschaltet, als „gebaut, nicht belegt" gekennzeichnet
2026-11-08	Video „Franz und die Glaskugel" (Animation KI-gestützt von einem Kollegen): erste Fassung stärker als die Belege („Genau das haben uns die Daten gezeigt", „rund 10 Prozent" ohne Ursache, „66 von 70" ohne Einschränkung); Vereinfachungen (9.325 vor der Korrektur, vier Runden statt zehn Iterationen)	Prüfung der Texte gegen die Berichte (Claude, Auftrag des Nutzers)	Texte eingeschränkt, Zahlen unverändert; Vereinfachungen im README genannt
2026-11-05	Paket B: Null als Ergebnis gelesen (0 von 84 Verfahren „B1 deutlich verfehlt"); tatsächlich Filterartefakt (Landkreis-Code am Lieferort fehlt bei nationalen Verfahren)	Robustheitsprüfung	Erste Auswertung nicht gültig; B1 nicht entscheidbar

9. Beiträge beider Teammitglieder

Stand 2026-11-09, Quelle `docs/beitraege.md`. Im Git steht nur ein Autor (alle Commits laufen über das Konto von Ludwig Richthammer, die Arbeit mit Claude Code eingeschlossen). Die Zuordnung stammt deshalb aus den Dokumenten und aus Angaben des

*Nutzers, nicht aus dem Git. **Manuel Strobel** (Kommilitone, Zweierteam) hat seine Beiträge noch nicht selbst eingetragen; was nicht aus den Dokumenten bekannt ist, steht als **offen: von Manuel nachzutragen**.*

Bereich	Ludwig Richthammer	Claude Code (KI-Assistenz)	Manuel Strobel
Fragestellung, Nische, Kriterien, Entscheidungen	Entscheidungen (Nische, „Idee anpassen", Prognoseziel Höchstende, Rücksprung zum Business Understanding, Sicht des Betriebs, Wunsch nach Demo und Live-Demo); Freigaben	Vorschläge, Entwürfe der Kriterien (vor den Ergebnissen committet)	offen: von Manuel nachzutragen
Daten, Aufbereitung, Auswertungen	Freigaben	Skripte (`src/`), Downloads, Tabellen	offen
Urteilsregeln 1.1, Blindprüfungen	geschrieben und kalibriert (2026-10-24); Urteile in Iteration 3 und 4 (W4 13/20; V4 17/20)	Schlüssel, Auswertung; Handsuche durch den Subagenten `rechercheur`	–
Zweitprüfung Iteration 5	P1 bis P13 (P11, P12 nicht beurteilt)	Vorlage, Schlüssel, Auswertung	P14 bis P71 (laut Nutzer, 2026-11-03)
Prüfung der Liste, KI-Leser	Prüfung der Stichprobe (Iteration 6)	Leser, Vergleichswert, Auswertung	15 Lose im TED-Original gelesen (Iteration 9, V6: 14/15)
Gespräche mit Betrieben und Vergabestelle	neun Anrufe, drei Stellen erreicht, Notizen ohne Namen (105 Minuten mit Vorbereitung)	–	offen
Evaluation	Entscheidungen	Subagent `evaluator` (kritische Prüfung)	offen
Business-Case-Auswahl, Demo, Live-Demo	Ideen und Wünsche (Make or Buy, Push-Matching, K-J, Live-Demo), Gegencheck der Angaben	Recherche-Agenten, Bewertung, Code der Demos	offen
Video „Franz und die Glaskugel"	Auftrag zur Prüfung der Texte	Prüfung gegen Belege, Korrekturen, Vertonung, Export	Animation von einem Kollegen KI-gestützt erstellt (laut Nutzer; ob von Manuel: **offen**); Autorenzeile im Abspann nennt Manuel und Ludwig, Manuels Anteil an der Korrektur: **offen**
Folien und Vortrag	Durchsicht, Freigaben	Foliengerüst und Umbau (`src/report/vortrag.py`)	Präsentation/Umsetzung (laut Nutzer, 2026-11-03; heutiger Stand: **offen**)
Dokumentation, Lab-Log	Durchsicht, Freigaben	Texte in `docs/` , `reports/`	offen

Verteilung laut Nutzer (2026-11-09): ca. 50:50, gemeinsame Telefonate; Details Manuel offen. **Offen bis zur Abgabe:** Manuel trägt seine Beiträge und Stunden selbst ein (`docs/beitraege.md` , Handeinträge im Zeitprotokoll). Bis dahin gelten für ihn nur die oben genannten Angaben; weitere werden nicht angenommen.

10. Zeitaufwand

Untergrenze aus der Git-Historie, insgesamt **43,5 Stunden** (Stand 2026-11-09, `src/zeitprotokoll.py` ; Sitzung = Commits mit höchstens 90 Minuten Abstand, plus 30 Minuten Vorlauf; Iteration 11 = Nachträge nach dem Tag `iteration-10` : Paket D, Business-Case-Auswahl, Demo, Live-Demo, Video, Folienumbau, Lab-Log). Enthalten ist die Rechenzeit von Claude. Nicht enthalten: Lesen, Handprüfung, Recherche (z. B. K-J, ohne Commit), Vortrag.

Iteration	Sitzungen	Commits	Stunden (Untergrenze)
1	2	3	1.7
2	2	4	1.4
3	4	22	6.3
4	7	19	7.8
5	3	18	3.5
6	1	4	3.6
7	3	12	4.4
8	2	5	1.3
9	2	10	1.9
10	3	21	4.4
11	5	32	7.4
Summe	34	150	**43.5**

Arbeitsschritte mit Zeitaufwand. Sitzungen anhand der Commit-Nachrichten zugeordnet (Näherung); „Handarbeit" nach Angaben des Nutzers. Gespräche (105 Minuten) und Manuels Beiträge: siehe Schätzung unten. Git-Spalte rund 36 Stunden (Iteration 1 bis 10) plus 7,4 Stunden Nachträge = 43,5 Stunden (rundungsbedingt).

Arbeitsschritt	Zugeordnete Git-Sitzungen	Git (Std., ca.)	Handarbeit außerhalb Git
Data Understanding (Abruf, Befüllungsquoten, Ursachen der Lücken)	Iteration 1 und 2, Paket C	3,6	nicht erfasst

Arbeitsschritt	Zugeordnete Git-Sitzungen	Git (Std., ca.)	Handarbeit außerhalb Git
Modellierung und Regeln (Zuordnung, Backtest, Regeln 1b, 6 bis 10)	Iteration 3, 4, 5, 7, 9 (Anteile)	10,5	–
Handprüfungen (Vorbereiten und Auswerten: Blindprüfungen, Handsuche, Zweitprüfung, Prüfung von 60 und 95 Losen)	Iteration 3 bis 7 (Anteile)	13,7	Ausfüllen der Prüfvorlagen durch den Nutzer: **offen**
KI-Lesung (Leser, Vergleichswert, Auswertung)	Iteration 8, 9 (Anteil), 10b	3,5	Kommilitone: 15 Lose in Iteration 9, Stunden **offen**
Business Understanding und Recherche (Wettbewerber, Wettbewerbsbild, Nebentest)	Iteration 4 (Anteil), 10 (Anteil)	2,1	–
Lab-Log, Folien, Dokumentation	Iteration 4, 5, 10 (Anteile)	2,8	Lesen der Berichte, Vortrag: nicht erfasst
Make or Buy, Business-Case-Auswahl, Demo, Live-Demo, Video, Folienumbau, Lab-Log-Nachträge	Iteration 11 (Nachträge nach `iteration-10`)	7,4	Wünsche, Gegencheck, Hörprobe des Videos: nicht erfasst

Schätzung des Gesamtaufwands (SCHÄTZUNG, nicht gemessen; Herleitung `docs/zeitprotokoll.md`). Nicht mitgestoppt; die Spannen sind Schätzungen von Claude mit angenommenen Minuten je Prüfeinheit, gemessen ist nur die Git-Zahl.

Block	Schätzspanne (Std.)	Grundlage
Git-Sitzungen (Untergrenze 43,5 h; enthält Rechenzeit von Claude)	30 bis 43,5	Annahme: 70 bis 100 % davon mit Mensch beteiligt
Blindprüfungen Iteration 3 und 4 (40 Paare, Nutzer)	3 bis 6	5 bis 9 Min. je Paar angenommen
Zweitprüfung Iteration 5: P1 bis P13 (Nutzer), P14 bis P71 (Manuel, laut Nutzer)	5 bis 10	71 Paare, 4 bis 8 Min. angenommen
Prüfung der Stichproben Iteration 6 und 7 (Nutzer, rund 60 Lose)	2 bis 4	2 bis 4 Min. je Los angenommen
15 Lose lesen (Manuel, Iteration 9)	1 bis 2	4 bis 8 Min. je Los angenommen
Gespräche W5 (Nutzer)	1,75	Angabe des Nutzers: 105 Min., nicht gestoppt
Lesen der Berichte und Entscheidungen (beide)	4 bis 8	rund 10 Iterationen, 25 bis 50 Min. je Iteration angenommen
Telefonate und Abstimmung außerhalb der Git-Sitzungen	2 bis 5	laut Nutzer „immer telefoniert“; ohne Doppelzählung angesetzt
Video (Abstimmung, Hörprobe; ohne Animation des Kollegen), Vortrag und Folien (Durchsicht; Umsetzung Manuel laut Nutzer)	3 bis 8	Hörprobe, Probevortrag und Vortrag offen, nicht eingerechnet
Summe	**rund 52 bis 88**	Summe der Spannen (51,75 bis 88,25)

Gesamt rund **52 bis 88 Stunden**; bei ungefähr 50:50 (Nutzer: gemeinsame Telefonate, alles zusammen ausgearbeitet) **rund 26 bis 44 Stunden je Person**; Richtwert des Dozenten ca. 30 Stunden je Person. **Verteilung 50:50 und Gesamtstunden sind Angaben und Schätzungen von Nutzer und Claude, bitte von beiden bestätigen.** Manuels dokumentierte Einzelarbeiten ergeben nur etwa 7 bis 15 Stunden, der Rest läge in gemeinsamen Besprechungen; Manuels Angaben: offen.

11. Reproduzierbarkeit und Quellen

- **Datensatzquelle.** TED (Tenders Electronic Daily, Amt für Veröffentlichungen der EU), Search API v3 (`https://api.ted.europa.eu/v3/notices/search`, anonym), eForms-Bekanntmachungen und ältere Formulare ab Oktober 2016, Deutschland, Haupt-CPV 909; Vergleichsdaten: Vergabeweiser-API (CC BY 4.0), Bekanntmachungsservice (CC0); Telefongespräche ohne Namen. Quellenliste und Lizenzen: `docs/quellen.md`.
- **Code und Daten.** Alle Schritte laufen als Skripte in `src/` (Abhängigkeiten in `requirements.txt`; Aufrufe in `docs/reproduzierbarkeit.md`); Make-or-Buy und Export: `src/report/make_or_buy.py`, `export_vertragsliste.py`; Demos: `src/demo/` (offline aus Auszügen im Repo); Video: `src/report/video_vertonung.py`, `video_export.py` (`.venv-video`, `docs/video/README.md`); Bilder dieses Logs: `src/report/lab_log_bilder.py`. Rohdaten unverändert in `data/raw` (nicht im Git); Abruf per `src/ted_download.py` (öffentliche Quelle); Repository: https://github.com/ludwigrichthammer9-web/vergabe_radar.
- **Vorab festgelegt.** Seeds, Kriterien und Skripte wurden vor dem Ziehen oder Abruf committet; Hashes und Commits im Anhang A. Ausnahmen: Abschnitt 5.
- **Quellen.** `docs/quellen.md` (TED Search API v3, Lizenz laut TED-Rechtsseite frei wiederverwendbar, vor Abgabe zu bestätigen; Vergabeweiser CC BY 4.0; AusschreibungsRadar `robots.txt` beachtet; Bekanntmachungsservice CC0; Preise `docs/business.md` §8; Annahmen `docs/annahmen.md`).
- **Quellen K-J** (Lesedatum 2026-11-06; „laut Seite“ nach der Recherche, nicht erneut abgerufen; Anbieterangaben):

- Power-Automate-Lizenzen, Seite ms.date 2026-10-17: M365-Lizenzen erlauben Standard-Konnektoren, Premium nicht enthalten. https://learn.microsoft.com/en-us/power-platform/admin/power-automate-licensing/deep-dive-on-specific-license
- HTTP-Aktion Premium, ms.date 2026-08-14: eine M365-Lizenz („seeded license“) deckt Premium-Funktionen wie HTTP-Aktionen nicht ab (indirekte Aussage, Artikel über Flows mit Dienstprinzipal). https://learn.microsoft.com/en-us/power-automate/assign-user-license-service-principal-flow
- Besitzer geplanter Flows braucht Premium, Stand 2026-09-22: https://learn.microsoft.com/en-us/power-platform/admin/power-automate-licensing/faqs . Preis Premium 13,00 € je Nutzer und Monat (jährlich, zzgl. MwSt.): https://www.microsoft.com/de-de/power-platform/products/power-automate/pricing
- Standard-Konnektoren: https://learn.microsoft.com/en-us/connectors/connector-reference/connector-reference-standard-connectors, https://learn.microsoft.com/en-us/connectors/office365/, https://learn.microsoft.com/en-us/connectors/teams/, https://learn.microsoft.com/en-us/connectors/planner/, https://learn.microsoft.com/en-us/connectors/rss/; Planner: https://learn.microsoft.com/en-us/graph/api/planner-post-tasks?view=graph-rest-1.0, https://learn.microsoft.com/en-us/planner/planner-for-admins
- Teams-Webhooks über Workflows ohne Premium: https://support.microsoft.com/en-us/office/create-incoming-webhooks-with-workflows-for-microsoft-teams-8ae491c7-0394-4861-ba59-055e33f75498
- Abschaltung Office-365-Konnektoren in Teams (18. bis 22.05.2026), Stand 2026-04-14: https://devblogs.microsoft.com/microsoft365dev/retirement-of-office-365-connectors-within-microsoft-teams/
- TED, gespeicherte Suchen und Alarme (bis 25, E-Mail, RSS): https://ted.europa.eu/en/about-ted, https://ted.europa.eu/en/help/my-dashboard, https://ted.europa.eu/en/help/ted-account
- service.bund.de, Suche mit RSS und Newsletter: https://www.service.bund.de/Content/DE/Ausschreibungen/Suche/Formular.html . Vergabeweiser, Alerts: https://vergabeweiser.de/ . AusschreibungsRadar, Preise (Watchlist 9 €, Starter 29 €, Business 79 €, Professional 149 €, netto): https://ausschreibungsradar.com/preise/ . subreport, Preise: https://subreport.de/ausschreibungen/produktuebersicht/

Anhang A. Seeds, Hashes und Commits

- **Iteration 6:** `src/prepare/stichprobe_iteration6.py`. **Iteration 7:** Seed 20261106, SHA-256 des Schlüssels `eade66c0…`. **Iteration 8:** Seed 20261108 für die Kontrolle, SHA-256 der Vorlage `5be683ad…`. **Iteration 9:** Seed 20261109, SHA-256 des Schlüssels `9dbf5c1a…`, der neuen Liste `5ec73364…`.
- **Iteration 10:** kein eigener Seed; die 70 Zufallslose der Iteration 9 (Schlüssel `9dbf5c1a…`), Skript `src/prepare/vergleich_iteration10.py`, Kriterien und Skript vor dem Abruf committet (`81a3b90`). Nebentest: Seed 20261111, Ziehung vor dem Nachsehen (`2002ac8`), Auswertung `0eeab99`.
- **Iteration 10b:** Seed 20261112, SHA-256 des Schlüssels `2cd00206…`, `src/prepare/stichprobe_iteration10b.py`; Hypothese, Kriterien und Seed vor dem Ziehen (`4f50436`), Ziehung (`9d63c59`), Abrufskript vor dem Abruf (`49bb198`), Abruf (`64a23e3`), Paket für die Leser vor den Antworten (`6b7e8d8`), Antworten unverändert (`69917ff`), Auswertung und Evaluator (`f6583cc`), Abschluss (`0419609`).
- **Pakete:** Paket A Seeds 20261113 (Handabgleich von 5 Losen) und 20261114 (3 Beispiel-Lose), beide im Skript `src/prepare/wettbewerbsbild_oberpfalz.py` vorab festgelegt (`ea5ebfb`); Paket F `d6e2335`; Paket C `79fd0df`; Paket B Kriterien `0e83dfa`.
- Die Reihenfolge der Commits belegt, dass Regeln und Kriterien vor dem Ziehen feststanden.

Anhang B. KI-Irrwege, vollständige Tabelle

Nur ergänzt, nie überschrieben (`docs/ki_irrwege.md`). Je Eintrag: Datum, was schieflief, wie es bemerkt wurde, Konsequenz.

Datum	Irrweg	Bemerkt durch	Konsequenz
2026-10-23	K2-Urteile und Zuordnungsregel stammten von derselben Hand (Claude)	Evaluator (evaluation_iteration2.md)	Handsuche durch getrennten Subagenten, Zweitprüfung durch den Nutzer
2026-10-25	Auf den Entwicklungsdaten hielt Claude 10–11 von 12 Vorschlägen für plausibel, im Test waren 11 von 24 korrekt	Test auf neuen Daten (evaluation_iteration3.md)	Regel verworfen; Testdaten strikt getrennt
2026-10-30	Iteration 4: Parser zählte „grundlaufzeit, hoechstende“ nicht mit, W5 zu niedrig (189 statt 297)	Evaluator (evaluation_iteration4.md)	Auswertung korrigiert, Nachtrag
2026-11-03	Kalibrierungsbeispiele der Urteilsregeln nicht aus der Zweitprüfung (Iteration 5) ausgeschlossen: 4 Paare identisch, 3 mit gleicher neuer Bekanntmachung	Nutzer beim Ausfüllen (P11, P12)	Paare werden abgezogen, in der Auswertung dokumentiert
2026-10-30	Lese-Regeln für das Höchstende nur an eForms-Texten getestet, 55 von 68 Backtest-Vorgängern stammen aus der Zeit vor eForms	Selbstprüfung beim Zusammenstellen der Paare	offen ausgewiesen, keine Nachjustierung
2026-11-04	Claude schrieb in der Auswertung der Zweitprüfung „‚Alles bestätigen‘ ist damit ausgeschlossen“; rechnerisch erreicht blindes Bestätigen der 57 echten Paare bei 10 abgelehnten Ködern schon 57/67 = 85,1 % (Schwelle 85 %)	Evaluator (Nachrechnung, `reports/evaluation_iteration5.md`)	Aussage in der Entscheidung nicht verwenden; X2 nur mit den Ködern (9/10) und den Abweichungen deuten
2026-11-04	Hinweis des Evaluators: Begründungen der Zweitprüfung (auch P1–P13) ähneln dem Stil der Handsuche; Nutzung von Hilfsmitteln nicht dokumentiert	Evaluator	Nutzer bestätigt KI-Unterstützung (Urteile „nur geschärft“); X2 nicht als unabhängige Bestätigung werten; A18 bleibt ungeprüft
2026-11-04	Iteration 6, Teil B: Claude stellte die „unabhängige“ Paarprüfung aus Paaren zusammen, die der Prüfer schon aus Iteration 5 kannte	Nutzer beim Ausfüllen („warum gibst du mir auch die selben Paare?!“)	Teil B zählt nicht; Aufbau im Protokoll als Fehler vermerkt
2026-11-04	Iteration 6: Die Prüfvorlage zeigte das Enddatum der Liste neben den Texten (Verankerung); Claude schrieb außerdem fälschlich, kein Eintrag der Oberpfalz sei geprüft, dabei war L6 in der Liste	Evaluator und Nachprüfung durch Claude	Iteration 7: Vorlage ohne Listenwerte, Aussage korrigiert
2026-11-04	Iteration 7: Regel 1b machte in der ersten Fassung L6, L14, L46 falsch (Kündigungsfristen als Dauer, Datum im Text als Beleg)	Entwicklungstest an den 60 Losen der Iteration 6	Regel eingeschränkt, vor dem Ziehen der Stichprobe committet
2026-11-04	Iteration 7: Die Zufallsstichprobe enthielt kein Los, das Regel 1b ändert (Entwicklungs-Notices ausgeschlossen); Claude merkte das erst nach dem Ziehen	Selbstprüfung nach dem Ziehen	Kriterium Y1r vor der Prüfung ergänzt; Typ „Festlaufzeit-Datum“ bleibt ungetestet

Datum	Irrweg	Bemerkt durch	Konsequenz
2026-11-04	Iteration 7: Claude versteckte Beginn, Ende und Dauer in der Vorlage, damit kein Listenwert verankert; die Quelle „Feld“ war damit ohne TED-Original nicht erreichbar, und 65 von 95 Einträgen lauteten „unbekannt“ (Y1 zunächst 25 %)	Auswertung (0 Datumsabweichungen, 67 Einträge „unbekannt“)	Nachprüfung der 68 Lose im Original; Aufbau als Fehler im Vorgehen vermerkt
2026-11-04	Iteration 7: Claude legte vor, dass die Nachprüfung die erste Abgabe ersetzt, und riet, das Enddatum des Feldes zu übernehmen, wenn der Text nicht widerspricht; bei den Regelwirkungs-Losen (z. B. L65) verschlechterte das einen zuvor richtigen Texteintrag	Auswertung der Nachprüfung (Y1r 8/15)	im Abschluss offen genannt; Eintrag des Prüfers nicht verändert
2026-11-04	Iteration 7: Das Höchstende sollte nur bei Änderung neu eingetragen werden; 15 Einträge „unbestimmbar“ blieben veraltet, Y2 war dadurch rechnerisch zu niedrig (61,7 % statt 90,6 % ohne diese)	Claude bei der Auswertung	beide Werte ausgewiesen, Y2 nur mit Vorbehalt
2026-11-04	Korrektur zum Eintrag „Nachprüfung ersetzt die erste Abgabe“: Claude schrieb, das habe bei L65 einen zuvor richtigen Texteintrag verschlechtert. Das gilt nur für die unfertige erste Datei (`…_abgabe1.csv`); in der maßgeblichen zweiten Abgabe stand bei L65 und L88 „unbekannt“. Dieselbe falsche Aussage steht in `docs/iterationen.md` (Befund 3 der Nachprüfung)	Evaluator (evaluation_iteration7.md)	Nachtrag in `docs/iterationen.md` ; der Kern bleibt: Bei allen 7 Abweichungen der Regelwirkungs-Lose übernahm die Nachprüfung das Feld
2026-11-04	Iteration 7: Claude schrieb im Prototyp, Stufe A sei „die sicherste“, obwohl die Regel-1b-Lose (Stufe A per Definition) nur 8/15 erreichten, und in der Auswertung „Quelle laut Prüfer“, obwohl die Quelle der Nachprüfung von Claude abgeleitet war; außerdem „Liste = Rohdaten“ als Tatsache für L16, L30, L32 (an TED nur L26 bestätigt)	Evaluator (evaluation_iteration7.md)	Formulierungen in den Skripten korrigiert und Berichte neu erzeugt; in `docs/iterationen.md` als Nachtrag richtiggestellt
2026-11-05	Iteration 8: Claude nannte die KI-Leser „blind“; sie hatten aber `CLAUDE.md` automatisch im Kontext (Satz: „Das Enddatum der Bekanntmachung ist manchmal schon das Höchstende“), und die Vorlage gab Regel 1b als Leseanweisung vor („kürzere feste Laufzeit gilt“, „Beginn + Dauer − 1 Tag“)	Evaluator (Gesamtprüfung) und Claude (Protokolle der Leser)	Im Abschluss offen genannt; Z2 mit beiden Zahlen (14/15, 11/15); Leser gelten als nicht unabhängig
2026-11-05	Iteration 8: Der Evaluator in Schritt 4a bestätigte 10 Übereinstimmungen mit demselben WebFetch-Hilfsmodell wie die Leser und kannte deren Werte; Z4 kann gemeinsame Auslassungen des Hilfsmodells nicht aufdecken	Evaluator (Schlussbemerkung)	Z4 als „schwach belegt“ berichtet
2026-11-05	Iteration 8: Claude formulierte die Kriterien ohne Antwort auf Lose ohne Zuschlag und fehlerhafte Los-Zuordnung (Regel 6); L69, L72, L81 fielen erst dem Evaluator auf	Evaluator (Gesamtprüfung)	als offene Grenzen ins Lab-Log; keine Regeländerung
2026-11-05	Iteration 9: Claude legte V4 mit zwei Schwellen (≥ 90 % und ≥ 85 %) ohne Verknüpfung und ohne Folge in „Was folgt“ fest; die erste Schwelle wurde verfehlt (87,1 %), die zweite knapp erfüllt (85,2 %)	Evaluator (evaluation_iteration9.md)	nachträglich „beide müssen gelten“ gewertet und als Lücke der Vorab-Festlegung ausgewiesen
2026-11-05	Iteration 9: Claude schrieb zunächst, bei Los N51 liege ein Lesefehler von Leser B vor; im XML steht `TenderResultCode: unpublished` mit `FieldsPrivacy` „geschäftliche Interessen“, also nicht veröffentlicht, nicht „kein Zuschlag“. Die Anweisung an die Leser deckte den Fall nicht ab, B befolgte sie wörtlich	Evaluator und Nachprüfung am XML	Aussage „Lesefehler“ zurückgenommen; V7 bleibt nach dem Kriterium verfehlt (1 von 100), Ursache in der Anweisung

Datum	Irrweg	Bemerkt durch	Konsequenz
2026-11-05	Iteration 9: Das Lauf-Skript für die Leser (`leser_lauf_iteration9.ps1`) wurde erst zusammen mit den Antworten committet, und die Abweichung vom Plan (Skriptläufe statt Sitzungen im Fenster) stand zunächst nicht in `docs/iterationen.md` ; geprüft wurde nur der Eltern-Ordner auf eine `CLAUDE.md` , nicht `~/.claude`	Evaluator (Gesamtprüfung)	Nachtrag in `docs/iterationen.md` ; V8 nur „teilweise“; die 230 Dateien der Pakete per SHA-256 als byte-gleich belegt
2026-11-05	Iteration 9: Claude legte Messaufbau und Kriterien fest, ohne dass die Stichprobe die beiden Fassungen der Liste trennt (nur 7 Regelwirkungs-Lose in 3 Bekanntmachungen, Gruppe R am Ende 2 statt 10 Lose); der Vergleichswert nutzt wie die Liste das Feld als Ende der Grundlaufzeit und ist teilweise zirkulär; die Basisregel „Feld EndDate“ (63/70) wurde erst nachträglich berechnet	Claude (vor dem Ziehen, Präzision 1) und Evaluator	V3 (66 gegen 65 von 70) als kaum aussagekräftig berichtet; „Fehlerarten behoben, Stichprobe bestätigt“ nicht behauptet
2026-11-05	Business Understanding: Claude fand am 2026-10-24 in zwei Suchen keinen deutschen Dienst für auslaufende Verträge und schrieb das in `docs/business.md` §6; die Sichtung der Wettbewerber (Projektplan G1.1) blieb danach offen. Tatsächlich bieten Vergabeweiser (kostenlos, 1.005 Reinigungsverträge) und AusschreibungsRadar genau diese Funktion, mit Daten auch unterhalb der EU-Schwelle	Recherche-Agent, beauftragt nach dem Hinweis des Dozenten auf mehr Business Understanding; beide Seiten von Claude nachgelesen	A2 widerlegt; `docs/business.md` §8; die Iterationen 5 bis 9 arbeiteten an einer Liste, die es kostenlos schon gibt; im Lab-Log offen genannt
2026-11-05	Liste, Regel `beginn_plus_dauer` : Das Dauerfeld wird als Grundlaufzeit gelesen, auch wenn es die Option schon enthält (Beispiele: 527230-2026 „4 Monate + 6 Monate Option = 10 Monate“; 533946-2026 „2 Jahre Festlaufzeit + 3×1 Jahr Option“, Dauerfeld 5 Jahre, Liste Ende 30.09.2031 statt 30.09.2028). Claude schrieb im ersten Nachtrag, nur 527230-2026 sei betroffen (grobe Textprüfung, 3 Treffer); Paket C fand 12 Lose in 5 Bekanntmachungen	Nutzer (Hinweis auf 527230-2026), dann Paket C (Agent, Prüfung von 407 Losen mit Textherkunft), zwei Fälle von Claude am Rohtext bestätigt	Fehlerart offen im Lab-Log (0,13 % der Liste, 12 von 9.325 Lose); Liste (Fassung 9) bleibt eingefroren, Messungen unverändert; Aussage „nur dieser Fall“ im Nachtrag in `docs/iterationen.md` richtiggestellt
2026-11-05	Iteration 10b: Claude legte die Schwelle W8a (Vorsprung ≥ 16 Lose = 10 % von 160) fest, indem er die Diskordanzrate der Iteration 10 (12/70 = 17 %) übernahm; tatsächlich waren nur 15 von 160 Losen diskordant, die Schwelle war damit rechnerisch unerreichbar. Außerdem gab es keine Folgeregel für „W8a verfehlt, W8b erfüllt“, und das Skript gibt den Satz „Abweichungen von der Vorab-Festlegung: keine“ fest aus	Claude nach dem Abruf (vor den Leserantworten) und Evaluator (evaluation_iteration10b.md)	Kriterium nicht nachträglich geändert; im Ergebnis „formal verfehlt, rechnerisch unerreichbar“ mit gemessener Differenz (+15, p = 0,0001) ausgewiesen; Folge der Vorab-Regel nicht als Gleichheit gelesen
2026-11-05	Iteration 10b: Die Zuordnung zu Vergabeweiser über die Verfahrenskennung (Weg 2) ordnete bei M54 (346782-2025) einen fremden Eintrag zu (Vreden statt Lengerich), und M7 wurde durch die Reihenfolge der Ursachenklassen als „Losebene“ statt „Höchstende“ geführt (begünstigt Vergabeweiser in W8b)	Evaluator (Gesamtprüfung)	M54 gehört nicht zu „Vergabeweiser liest falsch“; W8b mit M7 als Höchstende wäre +11 statt +10; als Grenzen im Ergebnis genannt
2026-11-05	Paket B: Die erste Auswertung (Filter auf NUTS-3-Codes der Oberpfalz) fand 0 von 84 Verfahren unterhalb der EU-Schwelle und wurde im Bericht als „B1 deutlich verfehlt“ gelesen; das Feld für den Lieferort trägt bei nationalen Verfahren meist nur NUTS-1 („DE2“, 71,2 %), sodass der Filter nationale Verfahren aussortierte	Claude (Misstrauen gegenüber der Null, bevor das Ergebnis in Lab-Log oder Folien kam) und die Robustheitsprüfung des Agenten	Erste Auswertung nicht gültig; mit Postleitzahl und Ortsliste 32 von 120 (26,7 %, Wilson 19,6–35,2 %), B1 nicht entscheidbar; Lernpunkt „Eine Null ist ein Verdachtsmoment, kein Ergebnis“

Datum	Irrweg	Bemerkt durch	Konsequenz
2026-11-08	Video „Franz und die Glaskugel“ (vom Kollegen KI-gestützt erstellt): Die erste Fassung formulierte stärker als die Belege, nämlich „Genau das haben uns die Daten gezeigt“ (die Antwort „Selbst bauen? Nein“ folgt aus einem Modell mit Annahmen, nicht aus einer Messung), „Der Unterschied bei rund 10 Prozent“ ohne Ursache (von 15 abweichenden Losen der Iteration 10b: 7 Höchstende, 4 Losebene, 4 sonstige; ein Qualitätsvorsprung ist nicht belegt), „66 von 70“ ohne den Hinweis auf nicht unabhängige KI-Leser und teils zirkulären Vergleichswert, und die Aussage der Vergabestelle ohne Einordnung. Außerdem steht „Liste fertig! 9.325 Verträge“ vor der Korrektur, die Zahl 9.325 gehört aber zur späteren Fassung der Iteration 9 (vorher 9.915).	Prüfung der Texte gegen `docs/iterationen.md`, `reports/evaluation_iteration10b.md`, `reports/optionsanalyse.md` (Claude, Auftrag des Nutzers)	Texte in `docs/video/franz_und_die_glaskugel.html` eingeschränkt, Zahlen unverändert; die Zeitleiste vereinfacht den Projektverlauf (vier „Runden“ statt zehn Iterationen), die Zahl 9.325 bleibt als Vereinfachung, im README genannt (`docs/video/README.md`)
2026-11-06	Business-Case-Auswahl, Kandidat K-I (Push-Matching): Der Evaluator nahm an, Vergabeweiser biete „Benachrichtigungen per E-Mail, Teams, Slack oder Webhook“; die Startseite nennt nur „gespeicherte Suchen und E-Mail-Benachrichtigungen“	Nutzer-Gegencheck (WebFetch, vergabeweiser.de, 2026-11-06)	K2 von 0 auf 1 korrigiert, Summe 7 statt 6; Ergebnis unverändert (K7 = 0, als Kern ausgeschlossen); Nachtrag in `docs/business_case_auswahl.md`
2026-11-06	Demo, Vorgänger-Hinweis (Titelähnlichkeit zu einem Los der Prototyp-Liste): nur an einem erfundenen Titel getestet; im großen Datensatz (52 Oberpfälzer Bekanntmachungen) lagen alle 3 Auslösungen falsch (alte Fassung 2-mal die spätere Zuschlagsbekanntmachung desselben Verfahrens, neue Fassung 1-mal ein anderes Objekt, Score 0,75)	Prüfung am großen Datensatz der Live-Demo (Claude)	Funktion im großen Datensatz abgeschaltet und so beschriftet; als „gebaut, nicht belegt“ in `docs/demo_push.md` §4 und §11